



一. 组合优化——模拟退火、遗传。

1. 组合优化：有限解下的最优化

但解往往很多，枚举法X。

(一) 局部搜索

→ 衡量解好不好。

1. ① 初始解 ② 目标函数 $f(x)$ (如皇后问题：

③ 约束条件 $g(x)$ 。

$f(x)$ = 皇后冲突数)

⇒ 求 $\arg \min_x (f(x) | g(x))$

→ $f(x) \min$ 。

2. 核心：每次都选局部区域的最优解前进

1个可行解 ⇒ 一组可行解

注意：产生区域的方法：对每个解定义其邻域。

选取邻域最优解。

3. 产生邻域：① 常规交换法 (四皇后、旅行商)

② 逆序交换

③ 其它简单变换

4. (1) Q：局部搜索往往收敛于局部最优解。

A：ε - greedy 方法，每隔概率接受非最优解。

eg.



计算 x_i 被接受的概率：

若希望求 $f(x) \max$ ，则应该 $f(x_i) \uparrow$ ， $P(x_i) \uparrow$

于是令 $P(x_i) =$

$N(x_i)$

二. 统计机器学习

计算机 $\xrightarrow{\text{数据} + \text{统计方法}}$ 性能 $\uparrow$

1. 监督学习: 训练数据有标签 $\longrightarrow$ 分类任务

无监督: 无标签 $\longrightarrow$ 聚类任务

半监督

弱监督 $\equiv$ 强化学习

(一) 朴素贝叶斯方法: 有监督

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

x : 某类别样本 y : 分类输出 $= \{y_1, \dots, y_k\}$

目标: $\arg \max_y P(y_i | x)$: x 最可能分类

$$\textcircled{1} P(y_i | x) = \frac{P(x | y_i) P(y_i)}{P(x)} = P(x | y_i) P(y_i)$$

x 已给定 由训练集 $\checkmark$

2. 问题: 组合爆炸.

当 样本特征数, 特征取值, 类别数 太多.

$P(x | y_i)$ 可能严重退化. 太精确!!!

$\Rightarrow$ A: 假设各特征间独立. 单独算每个特征的概率再相乘 (独立性假设)

即:
$$P(y_i | x) = P(x | y_i) P(y_i) = \prod_{k=1}^N P(x_k | y_i) \cdot P(y_i)$$

3. P 累乘过小

$\Rightarrow$ 取对数. 累乘 $\rightarrow$ 累加.

4. 概率 $P(x_i | y_i) = 0$?

拉普拉斯平滑方法:


假设所有情况都出现过 1 次, 即 $x_i | y_i + 1$

为了概率归一, 分母 (总样本数) 也得加

(相当于人为给所有可能两情况生成了一个样本)

(二) 决策树.

利用样本特征构建树结构来分类.



问题: 特征使用顺序不同 $\rightarrow$ 树不同.

特征多 $\rightarrow$ 树多 $\rightarrow$ 组合爆炸.

理想决策树: ① 与训练集匹配度高

② 泛化能力好

思路：优先用分类能力强的特征进行分类

How 评价：

1. ID3 算法

(1) 数据集的熵 $\rightarrow$ 混乱程度.

$$H(D) = - \sum_{i=1}^N P_i \log_2(P_i)$$

$\downarrow$ 第 i 类样本概率.

P.S: $P_i = 0$. 定义 $P_i \log_2 P_i = 0$. $\rightarrow$ 对 $f(x)$ 图像看. 定义合理.

对某特征, 若使用其分类后子数据集 $H(D_i)$ 下降越多.

说明 D_i 越纯净, 特征分类能力 $\uparrow$

条件熵: $\rightarrow$ 所用特征.

$$H(D|A) = \sum_{i=1}^n \frac{|D_i|}{|D|} H(D_i) \quad \text{子数据集熵关于数据量占比的加权平均}$$

信息增益:

$$g(D, A) = H(D) - H(D|A)$$

$g \uparrow$, A 越好.

P.S: A 好不好和具体的 D 有关, 所以每次对于子数据集, 都要再重新计算 $g(D', A)$

ID3 算法
输入: 训练集 D , 特征集 A , 阈值 ϵ
输出: 决策树 T

- 1 如果 D 中所有样本均属于同一类别 C_k , 则 T 为单节点树, 将 C_k 作为该节点的类别标志, 返回 T
- 2 Δ 如果 A 为空, 则 T 为单节点树, 将 D 中样本最多的类 C_k 作为该节点的类别标志, 返回 T
- 3 否则计算 A 中各特征对 D 的信息增益, 选择信息增益最大的特征 A_g
- 4 Δ 如果 A_g 的信息增益小于阈值 ϵ , 则将 T 视为单节点树, 将 D 中样本最多的类 C_k 作为该节点的类别标志, 返回 T
- 5 否则按照 A_g 的每个可能取值 a_i , 将 D 划分为 n 个子数据集 D_i , 作为 D 的子节点
- 6 Δ 对于 D 的每个子节点 D_i , 如果 D_i 为空, 则视 T_i 为单节点树, 将 D_i 的父节点 D 中样本最多的类作为 D_i 的类别标志
- 7 否则以 D_i 作为训练集, 以 $A - \{A_g\}$ 为特征集, 递归地调用算法的 1~6 步, 得到子决策树 T_i , 返回 T_i

类似

用过的特征在子节点不能再用

2. C4.5 算法

ID3 的问题: 在选特征时, 倾向于选择取值可能

多的特征 $\Rightarrow$ 泛化能力 $\downarrow$ (过拟合)

根本原因: 样本不足 (子样本也会出现此问题)

分离信息: 本质上还是熵, 按特征取值概率计算熵

而非按概率计算熵.

特征不同取值的样本越平均, $SI(D, A) \uparrow$, 即熵 $\uparrow$

$$SI(D, A) = - \sum_{i=1}^n P_i \log_2 P_i$$

$\triangle$ 与 A 有关

$$P_i = \frac{D \text{ 中 } A \text{ 特征的某取值对应的样本数}}{D \text{ 中样本总数}}$$

SI 不仅针对 D , 还针对某个特征 A . $H(D)$ 只和 D 有关.

对 $SI(D, A)$ 可发现, A 取值越多, $SI(D, A) \uparrow$

$\therefore$ 用 $SI(D, A)$ 来作信息增益的惩罚项, 来解决特征取值 $\uparrow$. $g(D, A) \uparrow$ 的问题

信息增益率

$$g_r(D, A) = \frac{g(D, A)}{SI(D, A)} = \frac{H(D) - H(D|A)}{SI(D, A)}$$

C4.5: 按 $g(D, A)$ 选特征 $\longrightarrow$ 按 $g_r(D, A)$ 选特征

Attention Points:

① 选择不完全按 $g_r(D, A)$ 选.

选 $g(D, A)$ 较大的几个中 $g_r(D, A)$ 较大的
用 $g(D, A)$ 平均值判断.

A 是连续特征, 那么 A 还可以在子数据集中继续用

ID3 中, 阈值 ϵ 的设置其实就是一种预剪枝方法

① 通过验证集来剪枝，每次选一簇叶子，同时全剪掉，剩下的父亲成为叶子，选其概率最大的类别作为其标注。

③. 递归进行剪枝

叶子的熵 $\longrightarrow$ 叶子的混乱程度 $\longrightarrow$ 错误率

$$C(T) = \sum_{i=1}^N \frac{N(T_i)}{N} \left(\frac{N(T_i)}{N} + 2 \ln(T_i) \right) \rightarrow \text{树的复杂度}$$

叶子的样本数、叶子的熵、系数、叶子个数、错误率、平衡、复杂度

按样本加权的错误率 $\rightarrow$ 实际错误率

2 ↑ → 越简单的树, 反之.

方法：不用验证集错误率判断剪枝，直接用 $C(T)$ 是否下降作为判断条件。

4. 随机森林算法

大数据集 $\rightarrow n$ 份 $\rightarrow n$ 个决策树

按所有树的结果, 多数原则 $\rightarrow$ 最终结果

Q: 数据需求太多

A: 随机森林

① 随机有效回抽取数据构成 $\sim$ 树

② 对特征也做随机抽取.

可以不做剪枝, 可以一定程度上消除过拟合

(三) 支持向量机 (SVM)

到两类距离相等

1.




图 5.27 不同的“中间线”

A, B 都是中间线

最优分界线

距离最大的中间线

$\downarrow$ 高维

最优分界面 (超平面)

维度 $\rightarrow$ 特征数, 点 $\rightarrow$ 样本

原则上: SVM $\xrightarrow{\text{Only}}$ 分类

样本: (x_i, y_i)

$\rightarrow$ 对应类别

$x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})$

$y_i = \{1, -1\}$

样本, 空间中
的点

特征

(1) 最优平面: (w, b)

$w^* \cdot \vec{x} + b^* = 0$

如: 平面: $a_1 x_1 + a_2 x_2 + a_3 x_3 + b = 0$, $w = (a_1, a_2, a_3, b)$

(2) 每分类样本: x'

$$w^* \cdot \vec{x}' + b > 0, \text{ 平面 "上" 方} \rightarrow y' = 1 \text{ 类}$$

$$w^* \cdot \vec{x}' + b < 0 \quad \text{--- -- --} \rightarrow y' = -1 \text{ 类}$$

$y = f(x) = \text{sign}(w^* \cdot \vec{x} + b^*)$ 称为 决策函数. 只和支持向量有关 (见后)

$\hat{\gamma} = |w^* \cdot \vec{x} + b^*|$ 表示 $\vec{x}$ 到超平面的距离 $\rightarrow$ 函数间隔

易知: $\hat{\gamma} = \vec{y}_i \cdot (\vec{w} \cdot \vec{x}_i + b)$ $\rightarrow$ 但与超平面表亦有关
(比如 $w, b \rightarrow sw, sb$ 间隔可能变大)

归一化: 几何间隔: $\gamma_i = \frac{\hat{\gamma}_i}{\|w\|}$

$\hookrightarrow$ 点到超平面的距离

$\therefore$ 训练集 T 到 (w, b) 的几何间隔:

$$r = \min_i \gamma_i = \min_i \frac{\hat{\gamma}_i}{\|w\|}$$

根据 T 中样本分布不同分类:

1. 线性可分 SVM

若 T 求得 (w^*, b^*) 可将训练集中样本严格分开

$\rightarrow$ 求 (w^*, b^*) 即求

$$\max_{w, b} r \text{ 使得: } \underline{\gamma_i \cdot \left(\frac{w}{\|w\|} \cdot \vec{x}_i + \frac{b}{\|w\|} \right) \geq r}, \forall i$$

r implies r 是最小几何间隔

而 $r = \frac{\hat{\gamma}}{\|w\|}$ $\hat{\gamma}$ 函数间隔可任意收缩 (因为会随 w, b 的绝对大小而变化)

$\rightarrow$ 求 $\max_{w, r} r \Rightarrow \max_{w, b} \frac{1}{\|w\|}$, 使 $\gamma_i \cdot (\vec{w} \cdot \vec{x}_i + b) \geq 1$ Δ

使等号成立($\rho = 1$)的样本点就是支持向量。(见原文)

即由于已知线性可分, 则样本点一定满足

$\rho = 1$ 是距离最近的点了, 即支持向量。

Lagrange 乘子法

求 $\max \frac{1}{\|w\|} \Rightarrow \min \frac{1}{2} \|w\|^2$, 在约束 $1 - y_i(\bar{w} \cdot \bar{x}_i + b) \leq 0$

$$\text{构造 } L(w, b, \alpha) = \frac{1}{2} \|w\|^2 + \sum_{i=1}^N \alpha_i (1 - y_i(\bar{w} \cdot \bar{x}_i + b)) \quad (\alpha_i \geq 0)$$

$\Rightarrow$ 即求 $\min_{w, b} \max_{\alpha} L(w, b, \alpha)$

当满足 KKT 条件: $\min_{w, b} \max_{\alpha} L(w, b, \alpha) \Leftrightarrow \max_{\alpha} \min_{w, b} L(w, b, \alpha)$

KKT:

① 梯度为 0: $\frac{\partial L}{\partial w} = 0$ ± 1 , 修正方向

$$\Rightarrow \bar{w}^* = \sum_{i=1}^N \alpha_i^* y_i \bar{x}_i \quad (\text{向量加权求和})$$

$\hookrightarrow$ 意思是最优权重 $\bar{w}$ (平面法向量) 是支持向量的线性组合

同时说明了 α_i 的含义: 支持向量 $\bar{x}_i$ 的重要程度。

$$\frac{\partial L}{\partial b} = 0$$

$$\Rightarrow - \sum_{i=1}^N \alpha_i y_i = 0.$$

α_i 关于 y_i 加权和为 0. (后面求 α 最值会用到)

② 原始可行性: $1 - y_i(\bar{w} \cdot \bar{x}_i + b) \leq 0$

③ 对偶可行性: $\alpha_i \geq 0$

④ $\star$ 互补松弛性: 最核心的条件:

$$\underbrace{\alpha_i^*}_{\geq 0} \underbrace{(1 - y_i(\bar{w} \cdot \bar{x}_i + b))}_{\leq 0} = 0.$$

于是 α_i 和 $(1 - y_i(\bar{w} \cdot \bar{x}_i + b))$ 之间至少有 1 个为 0.

① 若 α_i 为 0, 则对应 $\bar{w} = \sum \alpha_i y_i \bar{x}_i$ 中

α_i 对应的 $\bar{x}_i$ 对 $\bar{w}$ 就不起作用

② 对于 $\alpha_i \neq 0$ 的点 $\bar{x}_i$, $y_i(\bar{w} \cdot \bar{x}_i + b) = 1$ 一定成立.

此时 $\bar{w} = \sum \alpha_i y_i \bar{x}_i$ 中, α_i 对应的 $\bar{x}_i$ 才起作用

即 $\alpha_i \neq 0$ 的 $\bar{x}_i$ 才对 $\bar{w}$ 做贡献 平面 (w^*, b^*) 只由这些



$y_i(\bar{w} \cdot \bar{x}_i + b) = 1$ 的 $\bar{x}_i$ 决定. 把这些向量叫作 支持向量

求解步骤.

① 求对偶问题 $\max_{\alpha, b} L(w, b, \alpha)$ 的解 α^*

② $w^* = \bar{x}_i$ 关于 α_i 线性组合 ($\alpha_i \rightarrow$ 重要性)

$$w^* = \sum_{i=1}^N \alpha_i^* y_i \bar{x}_i$$

③ 求 b^* : 对支持向量 $y_i(\bar{w}^* \cdot \bar{x}_i + b^*) = 1$

$$b^* = y_i - \bar{w}^* \cdot \bar{x}_i \quad \therefore \text{只选一个支持向量 (即选一个 } \alpha_i \neq 0 \text{ 的 } (\bar{x}_i, y_i) \text{ 代入求解即可)}$$

→ 化为: $\max_{\alpha} \left[\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\bar{x}_i \cdot \bar{x}_j) - \sum_{i=1}^N \alpha_i \right]$
使得 $\sum_{i=1}^N \alpha_i y_i = 0$. I. $\alpha_i \geq 0$. II

求解时: ① I 直接代入 (等式)

② 若求出了不满足 II, 则需分别求边界

($\alpha_1 = 0, \alpha_2 = 0 \dots \alpha_N = 0$) 条边下的最小值, 取其中最小的一组 α .

2. 线性 SVM

从函数间隔来的。

不可分: $\Rightarrow y_i (\bar{w} \cdot \bar{x}_i + b) \geq 1$ 不都成立?

$\Rightarrow$ 松弛: 那 $y_i (\bar{w} \cdot \bar{x}_i + b) \geq 1 - \xi_i$?

但希望 $\xi_i \neq 0$ 的尽量少, 尤其 $\xi_i > 1$ 的. 说明分类错误的
的尽量少:

$$\therefore \Rightarrow \min_{w, b} \left(\frac{1}{2} \|\bar{w}\|^2 + C \cdot \sum_{i=1}^N \xi_i \right)$$

$$\text{s.t. } y_i \cdot (\bar{w} \cdot \bar{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

C 为惩罚参数. $C \uparrow$, 惩罚 ξ_i 越严重, $\xi_i \downarrow$.

略去化简, 同用 Lagrange 乘子法, 得对偶问题:

$$\min \left(\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\bar{x}_i \cdot \bar{x}_j) - \sum_{i=1}^N \alpha_i \right)$$

$$\text{使 } \sum_{i=1}^N \alpha_i y_i = 0, \quad \text{且 } 0 \leq \alpha_i \leq C$$

和可分的比, 只有这不同.

① $C \rightarrow \infty$ 时, 退化为可分, 即惩罚严重, $\xi_i \rightarrow 0$.

② ξ_i 是中间变量, 实际不需要, 但可求:

① 非支持 ~: $\alpha_i = 0$, 间隔一定 > 1 , $\xi_i = 0$

② 可分支持: 即 $0 < \alpha_i < C$, 间隔 $= 1$, $\xi_i = 0$

③ 不可分: $\alpha_i = C$.

$$\text{有 } y_i \cdot (\bar{w} \cdot \bar{x}_i + b) = 1 - \xi_i$$

$$\Rightarrow \xi_i = 1 - y_i \cdot (\bar{w} \cdot \bar{x}_i + b)$$

3. 非线性 SVM.

数学上可证.

目标: 升维, 使高维空间中可用线性 SVM.

即: 作变换:

如 $x(1,2)$ $\phi(x) = (x^{(1)}, x^{(2)}, x^{(1)}x^{(2)})$

$\vec{x} \rightarrow \vec{\phi(x)}$ $\vec{\phi(x)}$ 维数更高.

于是样本 $(x_i, y_i) \longrightarrow (\vec{\phi(x_i)}, y_i)$

新空间线性 SVM

$$\min \frac{1}{2} \left[\sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\vec{\phi(x_i)} \cdot \vec{\phi(x_j)}) - \sum_{i=1}^N \alpha_i \right]$$

$$\text{s.t. } \sum_{i=1}^N \alpha_i y_i = 0 \text{ 且 } 0 \leq \alpha_i \leq C$$

$$\Rightarrow w^* = \sum_{i=1}^N \alpha_i^* y_i \vec{\phi(x_i)}$$

$$b^* = y_j - w^* \cdot \vec{\phi(x_j)} = y_j - \sum_{i=1}^N \alpha_i^* y_i (\vec{\phi(x_i)} \cdot \vec{\phi(x_j)})$$

$$\Rightarrow \text{平面, } w^* \cdot \vec{\phi(x)} + b^* = 0$$

$$\Rightarrow \sum_{i=1}^N \alpha_i^* y_i (\vec{\phi(x_i)} \cdot \vec{\phi(x)}) + b^* = 0.$$

Q: ① 维数升得太高 (甚至无限维), $\vec{\phi(x_i)} \cdot \vec{\phi(x_j)}$ 复杂

② 如何求 $\vec{\phi(x)}$?

$\Rightarrow$ (2) 核函数 $K(x_i, x_j)$

因为上面过程发现, 不需要知道 $\vec{\phi(x)}$ 具体多少, 只需要 $\vec{\phi(x_i)} \cdot \vec{\phi(x_j)}$ 即可. 于是直接定义

$$K(x_i, x_j) = \vec{\phi(x_i)} \cdot \vec{\phi(x_j)}$$

这样: $K(\vec{x}_i, \vec{x}_j)$ 实际是在原空间的函数. (变量 $\vec{x}_i, \vec{x}_j$)

自然: $K(x_i, x_j)$ 是非线性函数

$\Rightarrow$ 变为

$$\min \frac{1}{2} \left[\sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (K(\vec{x}_i, \vec{x}_j)) \right] \sum_{i=1}^N \alpha_i,$$

$$\text{s.t. } \sum_{i=1}^N \alpha_i y_i = 0 \text{ 且 } 0 \leq \alpha_i \leq C$$

$$\Rightarrow w^* = \sum_{i=1}^N \alpha_i^* y_i \vec{\phi}(x_i)$$

$$b^* = y_j - w^* \cdot \vec{\phi}(x_j) = y_j - \sum_{i=1}^N \alpha_i^* y_i (K(\vec{x}_i, \vec{x}_j))$$

$$\Rightarrow \text{平面: } w^* \cdot \vec{\phi}(x) + b^* = 0$$

$$\Rightarrow \sum_{i=1}^N \alpha_i^* y_i (K(\vec{x}_i, \vec{x})) + b^* = 0.$$

这样: w^* 无法直接显式求出, 但平面方程仍可求

P.S. 这个求出的直接是原空间超曲面, 因为变量是 $\vec{x}$

几个核函数.

(1) 多项式: $K(\vec{x}_i, \vec{x}_j) = (\vec{x}_i \cdot \vec{x}_j + c)^d$

(2) 高斯: $K(\vec{x}_i, \vec{x}_j) = \exp(-r \|\vec{x}_i - \vec{x}_j\|^2)$

$r \uparrow$: 拟合越精确

$r \downarrow$: 边界越平滑 (可能欠拟合)

(可能过拟合)

(3) Sigmoid: $K(x_i, x_j) = \tanh(r(\vec{x}_i \cdot \vec{x}_j) + c)$

4. SVM 解决多分类问题

1. 一对一法 (多)

2. 一对多法 (少) (偏向负类)

3. 层次法 (少) (将错就错)

三. 路径搜索.

BFS. DFS. Dijkstra

(一) A 算法

$S \rightarrow n$ 估计 $n \rightarrow t$

对结点 n : $f(n) = \underline{g(n)} + \underline{h(n)}$

A 算法可能找不到最优解.

Open 表和 Closed 表的机制解决的问题是

"需要重新扩展一个已扩展过的结点"

① 这种情况在 Dijkstra 是不会出现的, Dijk 不可能需要更新一个已经走过的点 (visited)

② 但在 A^* 中会出现, 因为引入了 $h(n)$. $h(n)$ 的不准确会改变原来结点扩展的顺序.

A 的结束条件:

① Open 表取出第一个结点 ($f(n)$ 最小点) 为 t

② Open 表空.

(二) A^*

令 $h(n) \leq \underline{h^*(n)}$ 真实 $h(n)$

可以通过放宽限制条件来设满足 A^* 的 $h(n)$

A^* 能找到最优解.

① $h_1(n) < h_2(n)$ ($h \uparrow$ 启发信息 $\uparrow$)

则 A_1 扩展节点数 $\geq A_2$ 扩展 $\sim$

且 A_2 扩展点一定 $\rightarrow A_1$ 扩展

② 平均分叉数: b 深度

$$N = \frac{(b^{d+1} - 1)}{b - 1}$$

扩展节点总数

2. 单调的 $h(n)$

问题: 前面讲的结点重复扩展.

核心: 第一次扩展 n 时, 应该找到 s 到 n 的
最短路径

$\Downarrow$

$$\left\{ \begin{array}{l} h(\underline{n_i}) - h(\underline{n_j}) \leq c(n_i, n_j) \quad (\text{三角不等式}) \\ h(t) = 0 \end{array} \right.$$

这样的 h : ① 满足 A^* 条件

② 且能够 $\leftarrow$

(三) 改进 A^*

若定义不出单调 $h(n)$, 修正 A^* 也能部分解决
重复扩展.

① 最优路径上所有点 $s, n_1, \dots, t$

有 $f^*(s) = f^*(n_1) = \dots =$ 路径长度.

而由 A^* 对 $h(n)$ 的限制 我们有

① 定理: $f(n) < f^*(s)$ 的点 一定被 A^* 扩展.

② A^* 扩展点一定 $f(n) \leq f^*(s)$

于是 $Open = (\dots \mid \dots)$

$\downarrow$
 $f(n) < f^*(s)$

单独拿出这些一定 $\sim$ 的点, 放入 $NEST$ 表 对这些点,
按 $g(n)$ 进行扩展 (也就是 Dijkstra 的顺序) 这样就能
避免重复扩展.

Q: $f^*(s)$ 未知?

A: 用 $\underline{f_m}$ 代替 $f^*(s)$.

$\downarrow$
已扩展的最大 $f(n)$

四. 神经网络

1. 一个神经元



即 输出: $O = g(\text{net}) = g(\sum x_i w_i + b)$

Sigmoid: 输出 (0, 1) 的值 (概率)

2. 训练: 梯度下降:

$$w_i^{\text{new}} = w_i^{\text{old}} + \Delta w_i$$

$$\Delta w_i = -\eta \cdot \frac{\partial E(w)}{\partial w_i}$$

Δ 步长

1) 算法: 随机梯度下降: (Sigmoid 函数导出)

① 样本 $\rightarrow$ 网络 $\rightarrow$ 输出

$O_k \in (0, 1)$

② 对输出层神经元 k : 误差项:

$$\delta_k = (t_k - O_k) O_k (1 - O_k)$$

理想值 $\downarrow$ 输出

③ 对隐含层神 $\sim h, \sim$

后继续加权和

$$\delta_h = O_h (1 - O_h) \sum_{k \in h \text{ 的后续}} \delta_k w_{kh}$$

④ 每个权值更新:

$$\Delta w_{ji} = \eta \delta_j x_{ji}$$

同 j 的输入

$$w_{ji} = w_{ji} + \Delta w_{ji}$$

即后一层 j 神经元来自前一层 i 的输入

(2) 交叉熵损失 ~


要求是个概率值

第 d 个样本 $\leftarrow$ $H_d(W) = - \sum_{k=1}^M t_{kd} \log_2(O_{kd})$

$$\Rightarrow H(W) = - \sum_{d=1}^N \sum_{k=1}^M t_{kd} \log_2(O_{kd})$$

(二) 卷积神经 ~ CNN

参数量计算:



CNN: $9 + 1 = 10$
 $\downarrow$ bias.

MLP: 输入: 25, 输出 9: $\Leftrightarrow$ 9个神经元:

$\therefore$ 共 $25 \times 9 + 9 = 234$
 $\downarrow$ bias.

① 多个卷积核: 1个卷积核 $\xrightarrow{\text{output:}}$ 1个通道

② 防止变小: 填充 0.

③ 多通道卷积:

• 卷积核的“厚度” = 输入通道数

• 计算和二维相同.

• 输出通道数 = 卷积核数

2	1	0	2	3
9	5	4	2	0
2	3	4	5	6
1	2	3	1	0
0	4	4	2	8

通道1

3	1	0	3	2
2	4	4	2	3
2	3	5	3	4
0	4	3	1	5
1	2	4	2	6

通道2

1	0	-1
-1	0	1
1	0	-1
-1	0	1
-1	0	1
-1	0	1

3×3×2卷积核

3×3×2也只是1个卷积核，只是厚度为“2”（输入通道数）

图 1.28 两通道卷积示意图

输出通道数为1

-3	-6	-9
13	1	9
5	-4	-6

输出为一个通道

$$\begin{aligned}
 &1 \times 2 + 0 \times 1 + (-1) \times 0 \\
 &+ (-1) \times 9 + 0 \times 5 + 1 \times 4 \\
 &+ 1 \times 2 + 0 \times 3 + (-1) \times 4 \\
 &+ (-1) \times 3 + 0 \times 1 + 1 \times 0 \\
 &+ (-1) \times 2 + 0 \times 4 + 1 \times 4 \\
 &+ (-1) \times 2 + 0 \times 3 + 1 \times 5 = -3
 \end{aligned}$$

④ 池化: pooling.

利用池化窗口的移动 $\left\{ \begin{array}{l} \text{max pooling} \\ \text{mean pooling} \end{array} \right.$

↓
数据压缩

- 池化作用在每个通道上，输入输出通道数一致

(三) 梯度消失

1. GoogleNet 的例子:

- inception 模块: 同一层用大小不同卷积核.
- 改进的 inception: 前面加 1×1 卷积核.

目标是 $\left\{ \begin{array}{l} \text{特征组合} \\ \text{降维} \end{array} \right.$

(因为输出通道数 = filter 数)

2. ResNet 残卷网络

残差模块




图 1.40 残差模块示意图

(四) 过拟合:

1. 正则化项法

$$E_d(W) = \sum_{k=1}^M (t_{kd} - O_{kd})^2 + \underbrace{\frac{1}{2} \|W\|_2^2}_{\text{正则化项}}$$

$W_1^2 + W_2^2 + \dots + W_N^2$

让损失函数小, 尽量让 W 小, 即权重不那么复杂

2. 舍弃法: (Drop out)

3. 数据增强法

(五) RNN




图 1.54 与图 1.53 对应的循环神经网络示意图

每个小的 RNN 单元 其实都是 1 个小的全连接层

输出的 $h^{(t)}$ 都是向量, 维数和全连接神经元个数一致

① 若作情感分类 (分类)

可在最后输出 $h^{(t)}$ 前再加上 1 个小的全连接层, 然后通过 softmax 函数输出不同类别的概率分布.

② 不定长文本:

事实上只有 1 个子网络, 自己进行循环, 也就是不同的词用同样的参数.

③ 分词问题 $\longrightarrow$ 分类问题.

B. E. M. S.

④ 向量 $\longrightarrow$ 序列

把向量作为所有子网络 (RNN 模块) 的输入

⑤ 序列 $\longrightarrow$ 序列:

Encoder $\longleftrightarrow$ Decoder

序列 $\longrightarrow$ 向量 ($h^{(t)}$) $\longrightarrow$ 序列.

五. 对抗搜索

1. 极小-极大

2. α - β 剪枝

加入剪枝的极小-极大模型

$$\begin{cases} \text{后极大} \leq \text{祖极大} & \checkmark \\ \text{后极大} \geq \text{祖极小} & \checkmark \end{cases} \quad \text{等于也剪!}$$

3. MCTS

UCB:
$$I = \bar{X} + \sqrt{\frac{2 \ln(n)}{T(n)}}$$

$\bar{X}$ $\downarrow$ 该结点收益

$T(n)$ $\rightarrow$ 该结点模拟次数

$\rightarrow$ 该层模拟总次数

① 一个结点的标号确定了, 再更新其父亲

② 更新父亲后, 要立即检查父亲能否剪枝